Лабораторная работа №4

Классификация или регрессия: Анализ набора данных

В качестве набора данных будем использовать датасет "HR Dataset". В датасете содержится информация о сотрудниках компании.
Ссылка на датасет: https://www.kaggle.com/datasets/imtiajemon/hr-dataset/data
Датасет содержит следующие поля.

1. **Employee_ID** - уникальный идентификатор сотрудника
2. **Name** - имя сотрудника
3. **Gender** - пол сотрудника
4. **Department** - отдел, в котором работает сотрудник
5. **EducationField** - область образования
6. **MaritalStatus** - семейное положение
7. **JobRole** - должность
8. **JobLevel** - уровень должности
9. **Age** - возраст
10. **MonthlyIncome** - месячный доход
11. **NumCompaniesWorked** - количество компаний, в которых работал сотрудник
12. **TotalWorkingYears** - общий стаж работы
13. **TrainingTimesLastYear** - количество тренингов за последний год
14. **YearsAtCompany** - стаж работы в компании
15. **YearsInCurrentRole** - стаж в текущей должности
16. **YearsSinceLastPromotion** - лет с последнего повышения
17. **YearsWithCurrManager** - лет с текущим менеджером
18. **Attrition** - увольнение (целевая переменная)

1. Загрузка и предварительный анализ данных

```
# Импорт необходимых библиотек
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler, OneHotEncoder,
PolynomialFeatures
from sklearn.impute import SimpleImputer
```

```python
from sklearn.linear_model import LinearRegression, LogisticRegression
from sklearn.svm import SVR, SVC
from sklearn.tree import DecisionTreeRegressor, DecisionTreeClassifier,
plot_tree
from sklearn.metrics import (mean_squared_error, r2_score,
                             accuracy_score, confusion_matrix,
                             classification_report, roc_auc_score)
from sklearn.pipeline import make_pipeline
from sklearn.compose import ColumnTransformer

# Загрузка данных
hr_data = pd.read_csv("HR_Data.csv")

# Просмотр первых строк датасета
hr_data.head()

# Основная информация о данных
hr_data.info()

# Статистическое описание числовых признаков
hr_data.describe(include='all')
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1473 entries, 0 to 1472
Data columns (total 24 columns):
 #   Column                    Non-Null Count  Dtype
---  ------                    --------------  -----
 0   EmpID                     1473 non-null   object
 1   Age                       1473 non-null   int64
 2   AgeGroup                  1473 non-null   object
 3   Attrition                 1473 non-null   object
 4   BusinessTravel            1473 non-null   object
 5   Department                1473 non-null   object
 6   DistanceFromHome          1473 non-null   int64
 7   EducationField            1473 non-null   object
 8   EnvironmentSatisfaction   1473 non-null   object
 9   Gender                    1473 non-null   object
 10  JobLevel                  1473 non-null   int64
 11  JobRole                   1473 non-null   object
 12  JobSatisfaction           1473 non-null   object
 13  MaritalStatus             1473 non-null   object
 14  MonthlyIncome             1473 non-null   int64
 15  Over18                    1473 non-null   object
 16  OverTime                  1473 non-null   object
 17  PercentSalaryHike         1473 non-null   int64
```

```
 18  PerformanceRating         1473 non-null   object
 19  TotalWorkingYears         1473 non-null   int64
 20  YearsAtCompany            1473 non-null   int64
 21  YearsInCurrentRole        1473 non-null   int64
 22  YearsSinceLastPromotion   1473 non-null   int64
 23  YearsWithCurrManager      1473 non-null   float64
dtypes: float64(1), int64(9), object(14)
memory usage: 276.3+ KB
```

	EmpID	Age	AgeGroup	Attrition	BusinessTravel	Department	
count	1473	1473.000000	1473	1473	1473	1473	
unique	1470	NaN	5	2	3	3	
top	RM1465	NaN	26-35	No	Travel_Rarely	Research & Development	
freq	2	NaN	607	1236	1045	963	
mean	NaN	36.917176	NaN	NaN	NaN	NaN	
std	NaN	9.130690	NaN	NaN	NaN	NaN	
min	NaN	18.000000	NaN	NaN	NaN	NaN	
25%	NaN	30.000000	NaN	NaN	NaN	NaN	
50%	NaN	36.000000	NaN	NaN	NaN	NaN	
75%	NaN	43.000000	NaN	NaN	NaN	NaN	
max	NaN	60.000000	NaN	NaN	NaN	NaN	

11 rows × 24 columns

2. Предобработка данных

2.1. Обработка пропущенных значений

```python
# Анализ пропущенных значений
print("Пропущенные значения до обработки:")
print(hr_data.isnull().sum())

# Заполнение пропусков (если есть)
# Например, для числовых признаков медианой, для категориальных - модой
numeric_cols = hr_data.select_dtypes(include=['int64', 'float64']).columns
categorical_cols = hr_data.select_dtypes(include=['object']).columns

for col in numeric_cols:
    if hr_data[col].isnull().sum() > 0:
        hr_data[col] = hr_data[col].fillna(hr_data[col].median())

for col in categorical_cols:
```

```
    if hr_data[col].isnull().sum() > 0:
        hr_data[col] = hr_data[col].fillna(hr_data[col].mode()[0])

# Проверка, что пропусков больше нет
print("\nПропущенные значения после обработки:")
print(hr_data.isnull().sum().sum())  # Должно быть 0
```

```
Пропущенные значения до обработки:
EmpID                     0
Age                       0
AgeGroup                  0
Attrition                 0
BusinessTravel            0
Department                0
DistanceFromHome          0
EducationField            0
EnvironmentSatisfaction   0
Gender                    0
JobLevel                  0
JobRole                   0
JobSatisfaction           0
MaritalStatus             0
MonthlyIncome             0
Over18                    0
OverTime                  0
PercentSalaryHike         0
PerformanceRating         0
TotalWorkingYears         0
YearsAtCompany            0
YearsInCurrentRole        0
YearsSinceLastPromotion   0
YearsWithCurrManager      0
dtype: int64

Пропущенные значения после обработки:
0
```

2.2. Кодирование категориальных признаков и выбор признаков

```
# Удалим ненужные столбцы (если есть)
hr_data = hr_data.drop(['EmpID', 'Over18'], axis=1)  # ID и константные
признаки

# Выберем признаки для модели
```

```
target = 'Attrition'
features = [col for col in hr_data.columns if col != target]

X = hr_data[features]
y = hr_data[target]

# Разделим признаки на числовые и категориальные
numeric_features = X.select_dtypes(include=['int64', 'float64']).columns
categorical_features = X.select_dtypes(include=['object']).columns

# Создаем преобразователь колонок
preprocessor = ColumnTransformer(
    transformers=[
        ('num', StandardScaler(), numeric_features),
        ('cat', OneHotEncoder(), categorical_features)
    ])

# Применяем преобразования
X_processed = preprocessor.fit_transform(X)
```

3. Разделение данных на обучающую и тестовую выборки

```
X_train, X_test, y_train, y_test = train_test_split(
    X_processed, y, test_size=0.2, random_state=42, stratify=y)

print(f"Train size: {X_train.shape[0]}")
print(f"Test size: {X_test.shape[0]}")
```

```
Train size: 1178
Test size: 295
```

4. Обучение моделей

4.1 Логистическая регрессия (для классификации)

```
logreg = LogisticRegression(max_iter=1000)
logreg.fit(X_train, y_train)

# Предсказания
y_pred_logreg = logreg.predict(X_test)
y_prob_logreg = logreg.predict_proba(X_test)[:, 1]

# Оценка качества
print("Logistic Regression:")
print(f"Accuracy: {accuracy_score(y_test, y_pred_logreg):.4f}")
print(f"AUC-ROC: {roc_auc_score(y_test, y_prob_logreg):.4f}")
```

```
print("\nClassification Report:")
print(classification_report(y_test, y_pred_logreg))
```

```
Logistic Regression:
Accuracy: 0.8915
AUC-ROC: 0.8584

Classification Report:
              precision    recall  f1-score   support

          No       0.91      0.97      0.94       248
         Yes       0.76      0.47      0.58        47

    accuracy                           0.89       295
   macro avg       0.83      0.72      0.76       295
weighted avg       0.88      0.89      0.88       295
```

4.2 Метод опорных векторов (SVM)

```
svm = SVC(probability=True, random_state=42)
svm.fit(X_train, y_train)

# Предсказания
y_pred_svm = svm.predict(X_test)
y_prob_svm = svm.predict_proba(X_test)[:, 1]

# Оценка качества
print("SVM:")
print(f"Accuracy: {accuracy_score(y_test, y_pred_svm):.4f}")
print(f"AUC-ROC: {roc_auc_score(y_test, y_prob_svm):.4f}")
print("\nClassification Report:")
print(classification_report(y_test, y_pred_svm))
```

```
SVM:
Accuracy: 0.8847
AUC-ROC: 0.8489

Classification Report:
              precision    recall  f1-score   support

          No       0.88      0.99      0.94       248
         Yes       0.88      0.32      0.47        47
```

```
    accuracy                           0.88       295
   macro avg       0.88      0.66      0.70       295
weighted avg       0.88      0.88      0.86       295
```

4.3 Дерево решений

```python
tree = DecisionTreeClassifier(max_depth=3, random_state=42)
tree.fit(X_train, y_train)

# Предсказания
y_pred_tree = tree.predict(X_test)
y_prob_tree = tree.predict_proba(X_test)[:, 1]

# Оценка качества
print("Decision Tree:")
print(f"Accuracy: {accuracy_score(y_test, y_pred_tree):.4f}")
print(f"AUC-ROC: {roc_auc_score(y_test, y_prob_tree):.4f}")
print("\nClassification Report:")
print(classification_report(y_test, y_pred_tree))
```

```
Decision Tree:
Accuracy: 0.8576
AUC-ROC: 0.7279

Classification Report:
              precision    recall  f1-score   support

          No       0.86      0.99      0.92       248
         Yes       0.73      0.17      0.28        47

    accuracy                           0.86       295
   macro avg       0.79      0.58      0.60       295
weighted avg       0.84      0.86      0.82       295
```

5. Сравнение моделей

```python
models = ['Logistic Regression', 'SVM', 'Decision Tree']
accuracy = [accuracy_score(y_test, y_pred_logreg),
            accuracy_score(y_test, y_pred_svm),
            accuracy_score(y_test, y_pred_tree)]
auc = [roc_auc_score(y_test, y_prob_logreg),
       roc_auc_score(y_test, y_prob_svm),
       roc_auc_score(y_test, y_prob_tree)]
```

```
comparison = pd.DataFrame({'Model': models, 'Accuracy': accuracy, 'AUC-ROC':
auc})
comparison.sort_values(by='Accuracy', ascending=False)
```

	Model	Accuracy	AUC-ROC
0	Logistic Regression	0.891525	0.858442
1	SVM	0.884746	0.848919
2	Decision Tree	0.857627	0.727908

6. Анализ важности признаков в дереве решений

```
# Получаем имена признаков после OneHot кодирования
feature_names = (preprocessor.named_transformers_['cat']

.get_feature_names_out(input_features=categorical_features))
feature_names = np.concatenate([
    numeric_features,  # числовые признаки
    feature_names
])

# Важность признаков
importances = tree.feature_importances_
indices = np.argsort(importances)[::-1]

# График важности признаков
plt.figure(figsize=(12, 8))
plt.title("Feature Importance in Decision Tree")
plt.bar(range(X_train.shape[1]), importances[indices], align="center")
plt.xticks(range(X_train.shape[1]), feature_names[indices], rotation=90)
plt.xlim([-1, X_train.shape[1]])
plt.tight_layout()
plt.show()
```

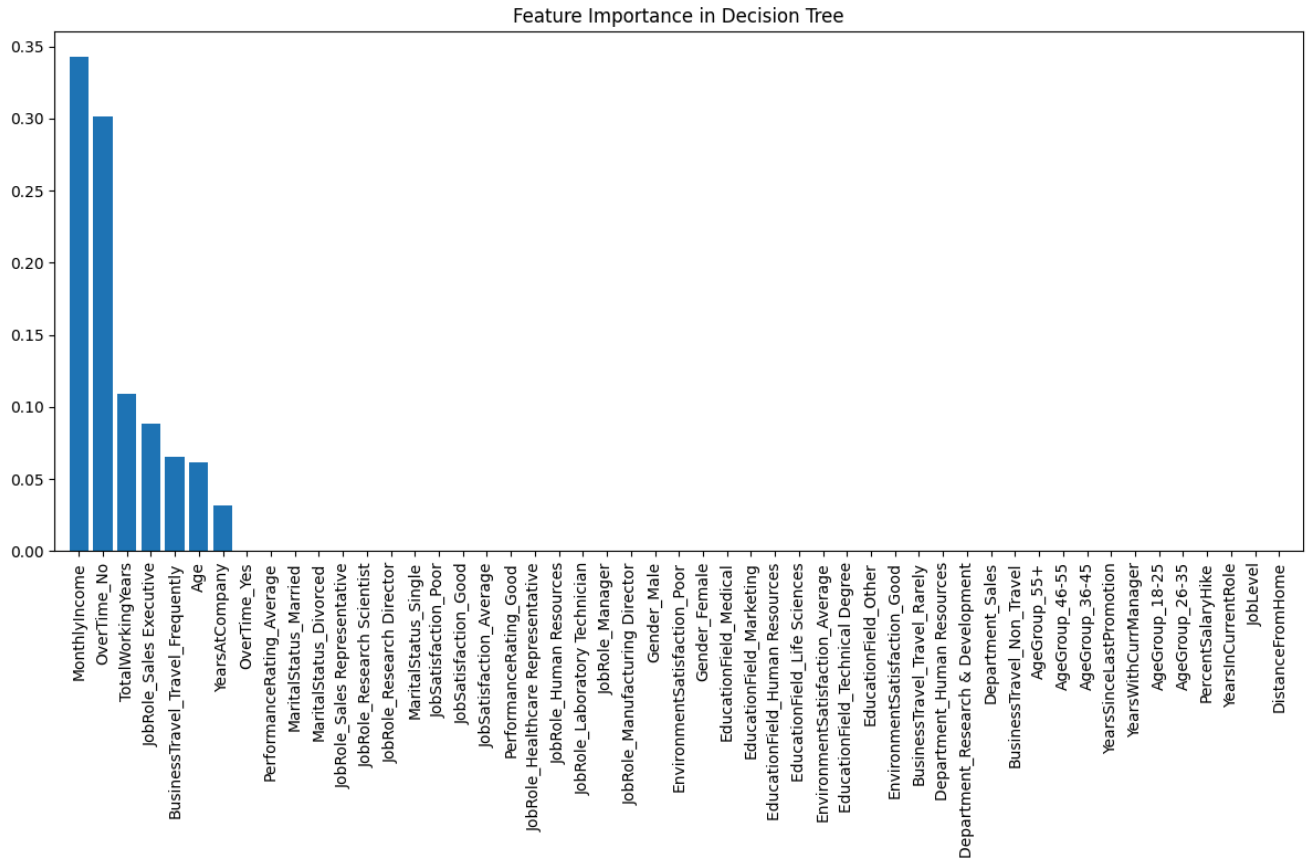

7. Визуализация дерева решений

```
plt.figure(figsize=(20, 10))
plot_tree(tree,
          feature_names=feature_names,
          class_names=['No Attrition', 'Attrition'],
          filled=True,
          rounded=True,
          proportion=True)
plt.show()
```

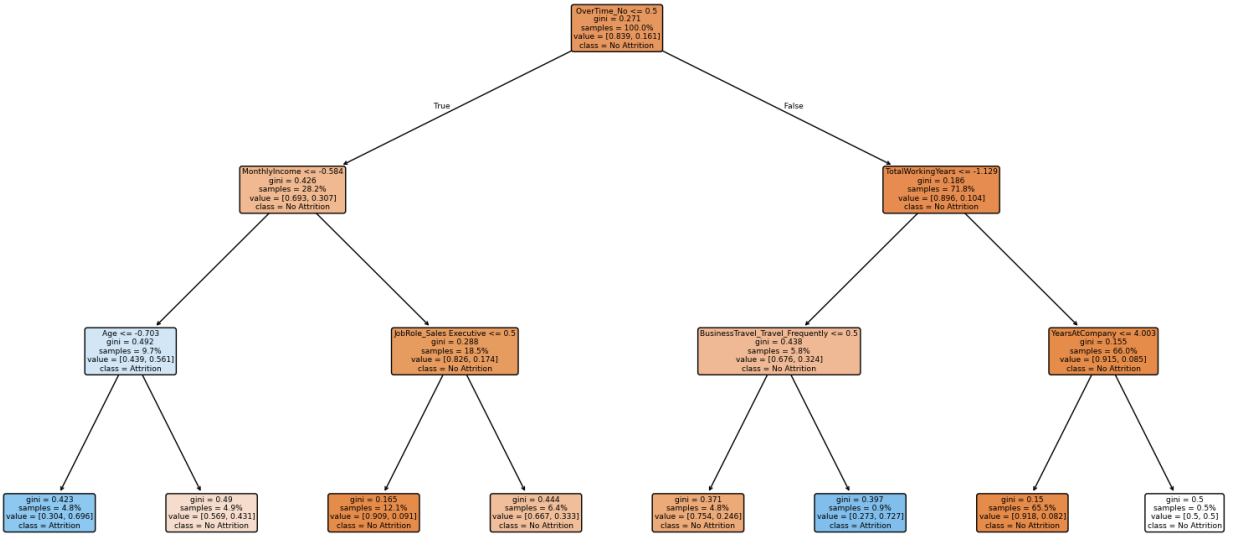

8. Вывод правил дерева решений в текстовом виде

```
from sklearn.tree import export_text

tree_rules = export_text(tree, feature_names=list(feature_names))
print(tree_rules)
```

```
|--- OverTime_No <= 0.50
|   |--- MonthlyIncome <= -0.58
|   |   |--- Age <= -0.70
|   |   |   |--- class: Yes
|   |   |--- Age >  -0.70
|   |   |   |--- class: No
|   |--- MonthlyIncome >  -0.58
|   |   |--- JobRole_Sales Executive <= 0.50
|   |   |   |--- class: No
|   |   |--- JobRole_Sales Executive >  0.50
|   |   |   |--- class: No
|--- OverTime_No >  0.50
|   |--- TotalWorkingYears <= -1.13
|   |   |--- BusinessTravel_Travel_Frequently <= 0.50
|   |   |   |--- class: No
|   |   |--- BusinessTravel_Travel_Frequently >  0.50
|   |   |   |--- class: Yes
|   |--- TotalWorkingYears >  -1.13
|   |   |--- YearsAtCompany <= 4.00
|   |   |   |--- class: No
|   |   |--- YearsAtCompany >  4.00
|   |   |   |--- class: No
```